

UNIVERSIDAD EL BOSQUE
Departamento de Matemáticas
Programa: Matemáticas y Ciencia de Datos

Análisis de riesgo de incumplimiento mediante un modelo de regresión Logit

Módulo 1, Unidad 1 — Guía de Aprendizaje 2
Actividades 3 y 4

Presentado por
Víctor Julio Peña

Curso
Inteligencia Artificial para Asuntos Financieros

Docente
William Arley Rincón Gómez

Bogotá D.C., 2025

1 Marco conceptual

El modelo *logit* es el modelo de referencia cuando la respuesta es **binaria**. En riesgo crediticio, $Y_i = 1$ si el cliente incumple y $Y_i = 0$ si cumple, con $Y_i \sim \text{Bernoulli}(p_i)$. No se modela la media directamente sino su transformación logit:

$$\text{logit}(p_i) = \ln\left(\frac{p_i}{1-p_i}\right) = \beta_0 + \sum_{j=1}^k \beta_j x_{ji} \quad \Longleftrightarrow \quad p_i = \frac{1}{1 + e^{-(\beta_0 + \sum_j \beta_j x_{ji})}}$$

El enlace logit se usa por dos razones: la función $\text{logit} : (0, 1) \rightarrow \mathbb{R}$ garantiza que la probabilidad predicha quede **acotada en** $(0, 1)$ —algo que un modelo lineal ordinario no asegura— y vuelve los parámetros **lineales en la escala de log-odds**, lo que da una interpretación cerrada. La estimación es por **máxima verosimilitud**, maximizando $\ell(\beta) = \sum_i [y_i \ln p_i + (1 - y_i) \ln(1 - p_i)]$ mediante el algoritmo IRLS que `glm()` implementa internamente; no hay solución cerrada como en mínimos cuadrados.

Interpretación. β_j es el cambio en el log-odds del evento ante un aumento unitario en x_j , *ceteris paribus*. Como esa escala no es intuitiva se reporta el **odds ratio** $\text{OR}_j = e^{\beta_j}$: si $\beta_j > 0$ entonces $\text{OR}_j > 1$ y la variable **aumenta** la probabilidad del evento; si $\beta_j < 0$, $\text{OR}_j < 1$ y la **reduce**; si $\beta_j = 0$, $\text{OR}_j = 1$ y no la altera. El logit **no** exige normalidad ni homocedasticidad —esos supuestos son del modelo lineal clásico—; exige linealidad en el logit, ausencia de multicolinealidad, independencia de las observaciones y tamaño de muestra suficiente por parámetro.

2 Modelo 1: simulación de 1.000 clientes

2.1 Simulación y ajuste

Se reproduce el diseño de la guía. Fue necesario corregir tres **errores de sintaxis** del código original: `seed(123)` no existe en R y debe ser `set.seed(123)`; la expresión de `lin_pred` tenía un paréntesis de cierre sobrante; y `glm()` se invocaba sin el argumento `data`, lo que obliga a que las variables vivan en el entorno global (mala práctica reproducible).

```
# set.seed() fija la semilla del generador pseudoaleatorio: es lo que hace
# REPRODUCIBLE la simulación (los mismos 1.000 clientes en cada corrida).
set.seed(123)
n <- 1000

# --- Variables explicativas: rnorm() = normal, rbinom() = Bernoulli -----
edad <- rnorm(n, mean = 40, sd = 10) # años
ingresos <- rnorm(n, mean = 3000, sd = 1000) # u.m. mensuales
score <- rnorm(n, mean = 600, sd = 50) # score crediticio
genero <- rbinom(n, size = 1, prob = 0.5) # 0 = femenino, 1 = masculino
monto_prestamo <- rnorm(n, mean = 5000, sd = 1500) # monto solicitado

# --- Predictor lineal: parámetros VERDADEROS del proceso generador (DGP) -----
lin_pred <- -3 - 0.03 * edad - 0.0004 * ingresos + 0.01 * score +
  0.8 * genero + 0.0001 * monto_prestamo

# --- Enlace inverso: del logit a la probabilidad, y respuesta Bernoulli -----
prob <- 1 / (1 + exp(-lin_pred))
default <- rbinom(n, size = 1, prob = prob) # 0 = cumple, 1 = incumple

datos1 <- data.frame(default, edad, ingresos, score, genero, monto_prestamo)

# family = binomial(link = "logit") declara respuesta Bernoulli con enlace logit;
# data = datos1 fija el ámbito explícito de las variables.
modelo1 <- glm(default ~ edad + ingresos + score + genero + monto_prestamo,
  family = binomial(link = "logit"), data = datos1)
summary(modelo1)
```

```
##
```

```
## Call:
## glm(formula = default ~ edad + ingresos + score + genero + monto_prestamo,
##      family = binomial(link = "logit"), data = datos1)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)  -0.9783100  1.1208247  -0.87    0.38275
## edad        -0.0342015  0.0083046  -4.12 0.000038154 ***
## ingresos    -0.0003151  0.0000822  -3.83    0.00013 ***
## score        0.0068442  0.0016859   4.06 0.000049123 ***
## genero       0.9407444  0.1688650   5.57 0.000000025 ***
## monto_prestamo 0.0000411  0.0000542   0.76    0.44840
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 1041.01  on 999  degrees of freedom
## Residual deviance:  955.06  on 994  degrees of freedom
## AIC: 967.1
##
## Number of Fisher Scoring iterations: 4
```

2.2 Interpretación de los coeficientes

Cuadro 1: Modelo 1. Parámetro verdadero del DGP frente al estimado, odds ratios e intervalos de confianza al 95 %. La última columna verifica que la estimación cubre el valor con que se simularon los datos.

	Variable	Beta real	Beta	EE	z	p-valor	OR	IC 95% inf	IC 95% sup	Beta real en el IC 95%
(Intercept)	(Intercept)	-3	-0.978	1.12	-0.87	0.3827	0.3759	0.0418	3.3820	Sí
edad	edad	-0.03	-0.0342	0.0083	-4.12	<0,0001	0.9664	0.9508	0.9822	Sí
ingresos	ingresos	-0.0004	-0.000315	0.0000822	-3.83	0.0001	0.9997	0.9995	0.9998	Sí
score	score	0.01	0.00684	0.00169	4.06	<0,0001	1.0069	1.0035	1.0102	Sí
genero	genero	0.8	0.941	0.169	5.57	<0,0001	2.5619	1.8400	3.5670	Sí
monto_prestamo	monto_prestamo	0.0001	0.0000411	0.0000542	0.76	0.4484	1.0000	0.9999	1.0001	Sí

Interpretar **ingresos** o **monto_prestamo** “por una unidad” es engañoso, porque una unidad monetaria es despreciable frente a una desviación estándar de 1.000 o 1.500. Por eso los efectos se reescalan a incrementos financieramente relevantes:

Cuadro 2: Modelo 1. Efectos sobre el riesgo de incumplimiento, reescalados a incrementos con sentido financiero.

Incremento evaluado	Cambio en log-odds	Odds ratio	Variación del riesgo (%)
edad (+1 año)	-0.0342	0.9664	-3.36
ingresos (+100 u.m.)	-0.0315	0.9690	-3.10
score (+10 puntos)	0.0684	1.0708	7.08
genero (hombre vs. mujer)	0.9407	2.5619	156.19
monto (+1.000 u.m.)	0.0411	1.0419	4.19

- **Edad** ($\hat{\beta} = -0.0342$): cada año adicional multiplica los odds de incumplimiento por 0.9664, reduciéndolos cerca de 3.4%. Actúa como factor protector.

- **Ingresos** ($\hat{\beta} = -0.000315$): cada 100 u.m. más de ingreso cambian los odds por un factor de 0.969; mayor capacidad de pago, menor riesgo.
- **Score** ($\hat{\beta} = 0.00684$): cada 10 puntos multiplican los odds por 1.0708. El signo es **positivo**, lo que es contraintuitivo y se discute en la Sección 2.4.
- **Género** ($\hat{\beta} = 0.941$): ser hombre multiplica los odds por 2.562 frente a ser mujer; es el efecto de mayor magnitud del modelo.
- **Monto** ($\hat{\beta} = 0.0000411$): cada 1.000 u.m. más multiplican los odds por 1.0419; mayor exposición, mayor riesgo, aunque es el efecto más débil.

Validación central del ejercicio: el parámetro verdadero del DGP queda contenido en el intervalo de confianza del 95% de su estimación en **6 de los 6 parámetros** (última columna del Cuadro 1). Esto confirma que la estimación por máxima verosimilitud es consistente y que el código recupera el mecanismo que generó los datos: el modelo no está “acertando por casualidad”, está identificando el proceso subyacente.

2.3 Verificación de supuestos y capacidad predictiva

Cuadro 3: Modelo 1. Diagnósticos del ajuste y desempeño predictivo.

Diagnóstico	Valor	Criterio de lectura
VIF máximo	1.01	< 5: sin multicolinealidad
Hosmer-Lemeshow (p-valor)	0.0808	> 0,05: buena calibración
R2 de McFadden	0.0826	0,05-0,40 es habitual en default
Razón de verosimilitud (p-valor)	<0,0001	< 0,05: el modelo aporta
Obs. influyentes (Cook > 4/n)	68	umbral 4/n = 0.004
AUC	0.6978	> 0,70 aceptable; > 0,80 buena
Exactitud (corte 0,5)	0.7900	solo referencial si hay desbalance
Sensibilidad	0.9885	detecta el evento y = 1
Especificidad	0.0651	detecta el no-evento y = 0




Figura 1: Modelo 1. Izquierda a derecha: logit empírico por deciles de cada covariable continua. La tendencia aproximadamente recta respalda el supuesto de linealidad en la escala logit.




Figura 2: Modelo 1. Curva ROC: recorre todos los puntos de corte y grafica sensibilidad contra 1 - especificidad. El AUC es la probabilidad de asignar mayor riesgo a un incumplidor que a un cumplidor.

Los VIF máximos cercanos a 1 son coherentes con covariables generadas de forma independiente: no hay multicolinealidad. El logit empírico es aproximadamente recto en las cuatro covariables continuas, como debía

ocurrir en un DGP construido lineal en el logit; es la confirmación de que el diagnóstico funciona. La prueba de Hosmer-Lemeshow arroja $p = 0.0808$, de modo que no se rechaza la buena calibración. El R^2 de McFadden (0.0826) es bajo en apariencia pero normal en modelos de *default*: la deviance residual absorbe la aleatoriedad binomial irreducible que el propio `rbinom()` introdujo. Con $AUC = 0.6978$ la discriminación es modesta, pero la matriz de confusión al corte 0,5 revela el problema del **desbalance**: la especificidad (0.065) es muy inferior a la sensibilidad (0.989), porque con una tasa de impago de 78.5% el modelo tiende a clasificar casi todo como incumplimiento. En producción el corte no debería ser 0,5 sino el que minimice el costo esperado (pérdida por impago frente a lucro cesante por rechazo).

2.4 Observación crítica sobre la especificación

El diseño de simulación de la guía produce dos resultados que merecen crítica explícita y no solo ser reportados:

1. **El signo de score contradice la teoría financiera.** El DGP fija $\beta_{score} = +0,01$: un mejor score **aumentaría** el riesgo. Pero el score es, por construcción, una puntuación decreciente en riesgo, de modo que lo coherente sería $\beta_{score} < 0$. El modelo recupera fielmente el $+0,01$ —correcto *como estimación*—, pero su lectura sustantiva no es trasladable a un caso real.
2. **La tasa base es implausible.** Evaluando el predictor lineal en las medias: $\eta \approx 1.5$ y por tanto $p \approx 0.818$. El término $+0,01 \times score \approx +6$ domina y anula el intercepto. Una cartera con 78.5% de impago no es viable.

Para medir el impacto se ajusta un **modelo de sensibilidad** idéntico, salvo el signo de **score** y la recalibración del intercepto:

Cuadro 4: Modelo 1. Efecto de corregir el signo de *score*: la estimación no cambia de calidad, pero sí la coherencia financiera del modelo.

Indicador	Especificación de la guía	Especificación corregida
Tasa de incumplimiento	78.5 %	1.3 %
Beta de score	0.0068	-0.0029
OR de score (+10 puntos)	1.0708	0.9712
AUC	0.6978	0.7668
R2 de McFadden	0.0826	0.0923

Con el signo corregido la tasa de impago baja a 1.3% y cada 10 puntos de score **reducen** los odds en 2.9%, que es la dirección esperada. La lección metodológica: **un modelo puede estar perfectamente bien estimado y ser inútil si el signo de la especificación no resiste la validación de negocio**. La revisión de signos es un paso obligatorio del *credit scoring*, anterior a cualquier métrica de ajuste.

3 Modelo 2: base Traindata, respuesta cumple

3.1 Carga de los datos y ajuste

Nota de reproducibilidad. Los resultados de esta sección provienen de la base SUSTITUTA simulada: el archivo Traindata del aula virtual no estaba disponible al compilar este documento. La estructura del análisis —ajuste, supuestos, interpretación— es idéntica para el archivo real; solo cambian las magnitudes numéricas.

La base tiene 1200 registros y 9 covariables, con una tasa de cumplimiento de **31.8%**. Es indispensable fijar la **dirección de la respuesta**: aquí el evento $Y = 1$ es *cumplir*, no incumplir, de modo que **todos los signos se leen al revés que en el Modelo 1**: $\beta_j > 0$ aumenta la probabilidad de cumplimiento y por tanto **reduce** el riesgo.

```
# La notación 'cumple ~ .' significa: cumple explicada por TODAS las demás
# variables del data.frame, que es exactamente lo que solicita la guía.
modelo2 <- glm(cumple ~ ., family = binomial(link = "logit"), data = traindata)
summary(modelo2)
```

```
##
## Call:
## glm(formula = cumple ~ ., family = binomial(link = "logit"),
##      data = traindata)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -4.0789775  0.7432992  -5.49 0.00000004073 ***
## edad           0.0146605  0.0060339   2.43  0.01511 *
## ingresos       0.0001973  0.0000421   4.68 0.00000280284 ***
## score          0.0063550  0.0009839   6.46 0.00000000011 ***
## genero        -0.3345805  0.1323685  -2.53  0.01148 *
## monto_prestamo -0.0000830  0.0000311  -2.67  0.00762 **
## plazo_meses    -0.0114310  0.0039116  -2.92  0.00347 **
## antigüedad_laboral 0.0612111  0.0189716   3.23  0.00125 **
## creditos_previos -0.1891168  0.0544755  -3.47  0.00052 ***
## tasa_endeudamiento -2.3650555  0.5363726  -4.41 0.00001036806 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 1499.9 on 1199 degrees of freedom
## Residual deviance: 1362.1 on 1190 degrees of freedom
## AIC: 1382
##
## Number of Fisher Scoring iterations: 4
```

3.2 Interpretación de los coeficientes

Cuadro 5: Modelo 2 (Traindata). Coeficientes, significancia, odds ratios e intervalos al 95 %. La respuesta es *cumple*: OR > 1 indica MENOR riesgo de crédito.

Variable	Beta	EE	z	p-valor	OR	IC 95% inf	IC 95% sup
(Intercept)	-4.07898	0.74330	-5.49	<0,0001	0.0169	0.0039	0.0726
edad	0.01466	0.00603	2.43	0.0151	1.0148	1.0028	1.0268
ingresos	0.00020	0.00004	4.68	<0,0001	1.0002	1.0001	1.0003
score	0.00635	0.00098	6.46	<0,0001	1.0064	1.0044	1.0083
genero	-0.33458	0.13237	-2.53	0.0115	0.7156	0.5521	0.9276
monto_prestamo	-0.00008	0.00003	-2.67	0.0076	0.9999	0.9999	1.0000

Variable	Beta	EE	z	p-valor	OR	IC 95% inf	IC 95% sup
plazo_meses	-0.01143	0.00391	-2.92	0.0035	0.9886	0.9811	0.9962
antiguedad_laboral	0.06121	0.01897	3.23	0.0013	1.0631	1.0243	1.1034
creditos_previos	-0.18912	0.05448	-3.47	0.0005	0.8277	0.7439	0.9210
tasa_endeudamiento	-2.36506	0.53637	-4.41	<0,0001	0.0939	0.0328	0.2688

Cuadro 6: Modelo 2. Odds ratios reescalados a incrementos financieramente interpretables, con su lectura de riesgo.

Variable	Incremento	OR reescalado	Cambio en odds de cumplir (%)	Lectura de riesgo	Signif. 5%
edad	5.0	1.0761	7.61	Menor riesgo	Sí
ingresos	500.0	1.1037	10.37	Menor riesgo	Sí
score	25.0	1.1722	17.22	Menor riesgo	Sí
genero	1.0	0.7156	-28.44	Mayor riesgo	Sí
monto_prestamo	1000.0	0.9204	-7.96	Mayor riesgo	Sí
plazo_meses	12.0	0.8718	-12.82	Mayor riesgo	Sí
antiguedad_laboral	1.0	1.0631	6.31	Menor riesgo	Sí
creditos_previos	1.0	0.8277	-17.23	Mayor riesgo	Sí
tasa_endeudamiento	0.1	0.7894	-21.06	Mayor riesgo	Sí

Resultan significativas al 5% las variables **edad**, **ingresos**, **score**, **genero**, **monto_prestamo**, **plazo_meses**, **antiguedad_laboral**, **creditos_previos**, **tasa_endeudamiento** (9 de 9). Recordando que el evento es *cumplir*:

- Las covariables con $\hat{\beta} > 0$ —edad, ingresos, score, antiguedad_laboral— **elevan la probabilidad de cumplimiento** y operan como factores protectores.
- Las covariables con $\hat{\beta} < 0$ —genero, monto_prestamo, plazo_meses, creditos_previos, tasa_endeudamiento— **reducen la probabilidad de cumplimiento** y funcionan como señales de alerta en la decisión de otorgamiento.
- Las no significativas no aportan evidencia suficiente de un efecto distinto de cero una vez controladas las demás. Son candidatas a eliminación en una etapa de selección de variables (AIC o regularización), pero **su exclusión no debe decidirse solo por el p-valor**: deben pesar también el criterio de negocio y la estabilidad del coeficiente.

3.3 Verificación de supuestos y capacidad predictiva

Cuadro 7: Modelo 2. Diagnósticos del ajuste y desempeño predictivo.

Diagnóstico	Valor	Criterio de lectura
VIF máximo	1.02	< 5: sin multicolinealidad
Hosmer-Lemeshow (p-valor)	0.2028	> 0,05: buena calibración
R2 de McFadden	0.0919	0,05-0,40 es habitual en default
Razón de verosimilitud (p-valor)	<0,0001	< 0,05: el modelo aporta
Obs. influyentes (Cook > 4/n)	44	umbral 4/n = 0.0033
AUC	0.7031	> 0,70 aceptable; > 0,80 buena
Exactitud (corte 0,5)	0.7000	solo referencial si hay desbalance
Sensibilidad	0.2467	detecta el evento y = 1
Especificidad	0.9109	detecta el no-evento y = 0
Eventos por variable (EPV)	42.3	>= 10: muestra suficiente




Figura 3: Modelo 2. Logit empírico por deciles de las covariables continuas de Traindata.




Figura 4: Modelo 2. Curva ROC sobre la base Traindata.




Figura 5: Modelo 2. Distribución de las probabilidades predichas según el resultado observado: cuanto menor el traslape, mayor la capacidad de discriminación.

El AUC de 0.7031 indica una capacidad de ordenamiento aceptable, los VIF descartan multicolinealidad y el EPV de 42.3 supera con holgura el mínimo de 10 recomendado, de modo que los errores estándar son confiables. Al mover el corte de 0,5 al óptimo de Youden (0.309) la exactitud pasa de 0.7 a 0.652; lo relevante no es ese cambio sino el reequilibrio entre sensibilidad (0.247 $\rightarrow$ 0.701) y especificidad (0.911 $\rightarrow$ 0.63). En cartera, aprobar a quien no paga y rechazar a quien sí paga tienen costos muy distintos, y es esa matriz de costos —no la exactitud— la que debe fijar el umbral.

4 Reflexión analítica

El logit es interpretable, y esa es su ventaja competitiva frente a modelos más potentes. En riesgo de crédito la interpretabilidad no es un lujo académico sino un requisito regulatorio y operativo. Un *gradient boosting* puede superar al logit en AUC, pero el logit entrega un odds ratio por variable que un comité de crédito puede auditar y que permite justificar ante un cliente por qué fue rechazado. El precio de esa transparencia es la

rigidez funcional —linealidad en el logit, ausencia de interacciones no declaradas— que precisamente por eso debe verificarse con diagnósticos y no darse por sentada.

Estimar bien no equivale a modelar bien. El Modelo 1 recuperó los parámetros verdaderos del DGP con precisión: cada estimación quedó dentro de su intervalo de confianza. Y sin embargo el modelo es sustantivamente defectuoso, porque el signo de `score` implica que un mejor historial aumenta el riesgo y porque la tasa de impago resultante (78.5%) no describe ninguna cartera real. Bastó corregir un signo y recalibrar el intercepto para obtener un comportamiento coherente. La validación de signos y de tasas base contra el conocimiento del negocio es, entonces, una etapa del flujo de trabajo tan obligatoria como la prueba de Hosmer-Lemeshow.

La IA generativa acelera el código pero no sustituye el juicio estadístico. Las herramientas de IA producen en segundos la sintaxis de una simulación y un `glm()`, y el código base de esta guía tiene ese origen. Pero también reprodujeron sin advertencia un `seed(123)` inexistente, un paréntesis desbalanceado, un `glm()` sin `data=` y un signo económicamente inconsistente. El valor que agrega el analista está justamente en lo que la herramienta no hace: fijar la dirección de la respuesta —`default` frente a `cumple` invierte toda la interpretación—, reescalar los efectos a incrementos con sentido financiero, verificar supuestos y elegir el punto de corte según la matriz de costos y no según la exactitud. Usada como copiloto de sintaxis bajo supervisión metodológica, la IA es un multiplicador de productividad; usada como oráculo, es un generador de modelos plausibles y equivocados.

5 Conclusiones

1. Se ajustaron los dos modelos logit solicitados. En el Modelo 1 la estimación por máxima verosimilitud recuperó los parámetros del proceso generador ($AUC = 0.698$), validando la implementación en R.
2. Los diagnósticos confirmaron ausencia de multicolinealidad ($VIF \approx 1$) y linealidad en el logit en ambos modelos: la especificación es estadísticamente admisible.
3. En el Modelo 2 sobre `Traindata`, con `cumple` como respuesta, el modelo alcanzó $AUC = 0.703$ y R^2 de McFadden = 0.092, con 9 de 9 covariables significativas al 5%.
4. La limitación principal es de especificación, no de estimación: el signo positivo de `score` en el diseño de la guía es incompatible con la teoría del riesgo de crédito, y corregirlo modifica tanto la tasa base como la interpretación gerencial del modelo.

6 Referencias

Contenido del Módulo 1, *Fundamentos de Inteligencia Artificial y Automatización de Procesos Financieros*. — Provost, F., & Fawcett, T. (2013). *Data Science for Business*. O'Reilly Media, caps. 1–2. — Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3.^a ed.). Wiley. — OECD (2021). *AI in Financial Markets: Applications and Policy Implications*. — McKinsey Global Institute (2018). *The age of analytics: Competing in a data-driven world*. — R Core Team (2024). *R: A Language and Environment for Statistical Computing*. Viena: R Foundation for Statistical Computing.

A Anexo A: código completo de R

```
# =====
# FUNCIONES AUXILIARES
# Se definen una sola vez y se reutilizan en los dos modelos del taller.
# Todas usan R base: el objetivo es que el cálculo sea seguible paso a paso.
# =====

# -----
# fmt(): formatea un número como TEXTO con cifras significativas fijas. Es
# necesario porque el hook de knitr para código en línea redondea con
# getOption("digits") y un coeficiente del orden de 1e-05 se imprimiría como 0.
# -----
fmt <- function(x, sig = 3) format(signif(x, sig), scientific = FALSE, trim = TRUE)

# fmt_p(): formatea p-valores evitando el engañoso "0.0000".
fmt_p <- function(x) ifelse(x < 0.0001, "<0,0001", format(round(x, 4), nsmall = 4))

# -----
```

```

# tabla_coeficientes(): convierte la salida de un glm en la tabla que realmente
# se interpreta en riesgo de crédito: coeficiente en escala logit, odds ratio
# OR = exp(beta) y su intervalo de confianza al 95 %.
# -----
tabla_coeficientes <- function(modelo, nivel = 0.95) {
  s <- summary(modelo)$coefficients # beta, error estándar, valor z, p-valor
  z <- qnorm(1 - (1 - nivel) / 2) # 1,96 para el 95 %
  b <- s[, "Estimate"]; se <- s[, "Std. Error"]
  out <- data.frame(
    rownames(s), round(b, 5), round(se, 5), round(s[, "z value"], 2),
    fmt_p(s[, 4]), round(exp(b), 4),
    round(exp(b - z * se), 4), round(exp(b + z * se), 4),
    row.names = NULL
  )
  # Los nombres se asignan aparte (y no como argumentos de data.frame) para que
  # el código sea válido en cualquier locale, incluso sin soporte UTF-8.
  names(out) <- c("Variable", "Beta", "EE", "z", "p-valor", "OR",
    "IC 95% inf", "IC 95% sup")
  out
}

# -----
# hosmer_lemeshow(): prueba de bondad de ajuste (calibración).
# Idea: se ordenan las observaciones por probabilidad predicha, se parten en g
# grupos (deciles de riesgo) y se comparan eventos OBSERVADOS vs. ESPERADOS:
#  $C = \sum_g (O_g - E_g)^2 / [E_g (1 - E_g/n_g)] \sim \chi^2_{(g-2)}$ 
# H0: el modelo está bien calibrado -> se DESEA un p-valor alto (no rechazar).
# -----
hosmer_lemeshow <- function(y, p, g = 10) {
  cortes <- unique(quantile(p, probs = seq(0, 1, length.out = g + 1)))
  grupo <- cut(p, breaks = cortes, include.lowest = TRUE)
  obs <- tapply(y, grupo, sum) # eventos observados por grupo
  esp <- tapply(p, grupo, sum) # eventos esperados por grupo
  n_g <- tapply(y, grupo, length) # tamaño de cada grupo
  C <- sum((obs - esp)^2 / (esp * (1 - esp / n_g)))
  gl <- length(levels(droplevels(grupo))) - 2
  list(estadistico = C, gl = gl, p_valor = pchisq(C, gl, lower.tail = FALSE))
}

# -----
# pseudo_r2_mcfadden():  $R^2 = 1 - deviance(modelo)/deviance(nulo)$ .
# NO es proporción de varianza explicada: mide la ganancia en log-verosimilitud
# frente al modelo que solo tiene intercepto.
# -----
pseudo_r2_mcfadden <- function(modelo) 1 - modelo$deviance / modelo$null.deviance

# -----
# matriz_confusion(): clasifica con un punto de corte y devuelve la matriz junto
# con exactitud, sensibilidad (detecta el evento y=1) y especificidad (y=0).
# -----
matriz_confusion <- function(y, p, corte = 0.5) {
  mc <- table(Observado = y,
    Predicho = factor(ifelse(p >= corte, 1, 0), levels = c(0, 1)))
  vn <- mc[1, 1]; fp <- mc[1, 2]; fn <- mc[2, 1]; vp <- mc[2, 2]
  list(matriz = mc, exactitud = (vp + vn) / sum(mc),

```

```

    sensibilidad = vp / (vp + fn), especificidad = vn / (vn + fp))
}

# -----
# tabla_diagnosticos(): consolida en UNA tabla todos los diagnósticos del
# modelo, con su criterio de decisión. Sustituye los volcados de consola por
# una salida legible y auditable.
# -----
tabla_diagnosticos <- function(modelo, y) {
  p <- fitted(modelo)
  hl <- hosmer_lemeshow(y, p)
  lr <- modelo$null.deviance - modelo$deviance          # estadístico LR
  gl <- modelo$df.null - modelo$df.residual
  mc <- matriz_confusion(y, p, 0.5)
  a <- as.numeric(auc(roc(y, p, quiet = TRUE)))
  out <- data.frame(
    c("VIF máximo", "Hosmer-Lemeshow (p-valor)", "R2 de McFadden",
      "Razón de verosimilitud (p-valor)", "Obs. influyentes (Cook > 4/n)",
      "AUC", "Exactitud (corte 0,5)", "Sensibilidad", "Especificidad"),
    # La columna se construye como TEXTO: mezcla conteos enteros, p-valores y
    # proporciones, y un formato numérico común los mostraría mal (p. ej. "68.0000").
    c(sprintf("%.2f", max(vif(modelo))), fmt_p(hl$p_valor),
      sprintf("%.4f", pseudo_r2_mcfadden(modelo)),
      fmt_p(pchisq(lr, gl, lower.tail = FALSE)),
      as.character(sum(cooks.distance(modelo) > 4 / length(y))),
      sprintf("%.4f", a), sprintf("%.4f", mc$exactitud),
      sprintf("%.4f", mc$sensibilidad), sprintf("%.4f", mc$especificidad)),
    c("< 5: sin multicolinealidad", "> 0,05: buena calibración",
      "0,05-0,40 es habitual en default", "< 0,05: el modelo aporta",
      paste0("umbral 4/n = ", round(4 / length(y), 4)),
      "> 0,70 aceptable; > 0,80 buena", "solo referencial si hay desbalance",
      "detecta el evento y = 1", "detecta el no-evento y = 0"),
    row.names = NULL
  )
  names(out) <- c("Diagnóstico", "Valor", "Criterio de lectura")
  out
}

# -----
# grafico_roc(): dibuja la curva ROC con ggplot2 a partir del objeto de pROC,
# para mantener un estilo gráfico homogéneo en todo el documento. La diagonal
# punteada es el clasificador sin información (AUC = 0,5).
# -----
grafico_roc <- function(objeto_roc, titulo = NULL) {
  d <- data.frame(fpr = 1 - objeto_roc$specificities,
    tpr = objeto_roc$sensitivities)
  a <- as.numeric(auc(objeto_roc))
  ggplot(d[order(d$fpr), ], aes(x = fpr, y = tpr)) +
    geom_abline(intercept = 0, slope = 1, linetype = "dashed",
      colour = "grey55", linewidth = 0.3) +
    geom_line(linewidth = 0.6) +
    annotate("text", x = 0.62, y = 0.18, size = 2.9,
      label = paste0("AUC = ", sprintf("%.4f", a))) +
    coord_equal(xlim = c(0, 1), ylim = c(0, 1)) +
    labs(x = "1 - Especificidad (falsos positivos)",

```

```

    y = "Sensibilidad (verdaderos positivos)", title = titulo)
}

# -----
# logit_empirico(): construye los datos para verificar el supuesto de
# LINEALIDAD EN EL LOGIT. Se parte cada covariable en k grupos de igual tamaño y
# en cada uno se calcula el log-odds observado, con corrección de
# Haldane-Anscombe (+0,5) para evitar log(0).
# -----
logit_empirico <- function(datos, respuesta, variables, k = 10) {
  y <- datos[[respuesta]]
  do.call(rbind, lapply(variables, function(v) {
    x <- datos[[v]]
    bin <- cut(x, breaks = unique(quantile(x, seq(0, 1, length.out = k + 1))),
               include.lowest = TRUE)
    do.call(rbind, lapply(split(data.frame(x = x, y = y), bin), function(b)
      data.frame(variable = v, x_medio = mean(b$x),
                  logit_emp = log((sum(b$y) + 0.5) /
                                   (nrow(b) - sum(b$y) + 0.5))))))
  )))
}

# set.seed() fija la semilla del generador pseudoaleatorio: es lo que hace
# REPRODUCIBLE la simulación (los mismos 1.000 clientes en cada corrida).
set.seed(123)
n <- 1000

# --- Variables explicativas: rnorm() = normal, rbinom() = Bernoulli -----
edad <- rnorm(n, mean = 40, sd = 10) # años
ingresos <- rnorm(n, mean = 3000, sd = 1000) # u.m. mensuales
score <- rnorm(n, mean = 600, sd = 50) # score crediticio
genero <- rbinom(n, size = 1, prob = 0.5) # 0 = femenino, 1 = masculino
monto_prestamo <- rnorm(n, mean = 5000, sd = 1500) # monto solicitado

# --- Predictor lineal: parámetros VERDADEROS del proceso generador (DGP) -----
lin_pred <- -3 - 0.03 * edad - 0.0004 * ingresos + 0.01 * score +
  0.8 * genero + 0.0001 * monto_prestamo

# --- Enlace inverso: del logit a la probabilidad, y respuesta Bernoulli -----
prob <- 1 / (1 + exp(-lin_pred))
default <- rbinom(n, size = 1, prob = prob) # 0 = cumple, 1 = incumple

datos1 <- data.frame(default, edad, ingresos, score, genero, monto_prestamo)
# family = binomial(link = "logit") declara respuesta Bernoulli con enlace logit;
# data = datos1 fija el ámbito explícito de las variables.
modelo1 <- glm(default ~ edad + ingresos + score + genero + monto_prestamo,
               family = binomial(link = "logit"), data = datos1)
summary(modelo1)
tasa1 <- mean(datos1$default)
p1 <- fitted(modelo1)
roc1 <- roc(datos1$default, p1, quiet = TRUE)
b1 <- coef(modelo1)
mc1 <- matriz_confusion(datos1$default, p1, 0.5)
eta_medio <- -3 - 0.03*40 - 0.0004*3000 + 0.01*600 + 0.8*0.5 + 0.0001*5000
tab1 <- tabla_coeficientes(modelo1)
# Parámetros verdaderos con que se generaron los datos, en el mismo orden que

```

```

# los coeficientes del modelo.
beta_real <- c(-3, -0.03, -0.0004, 0.01, 0.8, 0.0001)

# COBERTURA: se verifica si cada parámetro verdadero queda dentro del intervalo
# de confianza del 95 % de su estimación. Es la validación clave del ejercicio y
# se calcula, no se afirma.
ic1 <- confint.default(modelo1, level = 0.95)
cubierto <- beta_real >= ic1[, 1] & beta_real <= ic1[, 2]
cobertura1 <- sum(cubierto)

tab1$Beta <- sapply(coef(modelo1), fmt, sig = 3) # evita imprimir 0.0000411 como 0
tab1$EE <- sapply(summary(modelo1)$coefficients[, 2], fmt, sig = 3)
tab1 <- cbind(tab1[, 1, drop = FALSE],
              `Beta real` = sapply(beta_real, fmt, sig = 3),
              tab1[, -1],
              `Beta real en el IC 95%` = ifelse(cubierto, "Sí", "No"))
kable(tab1, booktabs = TRUE, linesep = "", align = "lrrrrrrrrrc",
      caption = "Modelo 1. Parámetro verdadero del DGP frente al estimado, odds ratios e intervalos de co
inc <- c(edad = 1, ingresos = 100, score = 10, genero = 1, monto_prestamo = 1000)
ef1 <- data.frame(
  c("edad (+1 año)", "ingresos (+100 u.m.)", "score (+10 puntos)",
    "genero (hombre vs. mujer)", "monto (+1.000 u.m.)"),
  round(b1[names(inc)] * inc, 4),
  round(exp(b1[names(inc)] * inc), 4),
  round(100 * (exp(b1[names(inc)] * inc) - 1), 2),
  row.names = NULL)
names(ef1) <- c("Incremento evaluado", "Cambio en log-odds", "Odds ratio",
               "Variación del riesgo (%)")
kable(ef1, booktabs = TRUE, linesep = "",
      caption = "Modelo 1. Efectos sobre el riesgo de incumplimiento, reescalados a incrementos con senti
kable(tabla_diagnosticos(modelo1, datos1$default), booktabs = TRUE, linesep = "",
      caption = "Modelo 1. Diagnósticos del ajuste y desempeño predictivo.")
le1 <- logit_empirico(datos1, "default",
                     c("edad", "ingresos", "score", "monto_prestamo"))
ggplot(le1, aes(x = x_medio, y = logit_emp)) +
  geom_point(size = 1) +
  geom_smooth(method = "lm", se = FALSE, linewidth = 0.4) +
  facet_wrap(~ variable, scales = "free_x", nrow = 1) +
  labs(x = "Valor medio del decil", y = "logit empírico")
grafico_roc(roc1)
set.seed(123) # misma semilla: cambia la especificación, no el azar
lin_pred_b <- -3 - 0.03 * edad - 0.0004 * ingresos - 0.01 * score +
             0.8 * genero + 0.0001 * monto_prestamo + 6 # signo corregido
default_b <- rbinom(n, 1, 1 / (1 + exp(-lin_pred_b)))
datos1b <- data.frame(default = default_b, edad, ingresos, score,
                     genero, monto_prestamo)
modelo1b <- glm(default ~ edad + ingresos + score + genero + monto_prestamo,
               family = binomial(link = "logit"), data = datos1b)
roc1b <- roc(datos1b$default, fitted(modelo1b), quiet = TRUE)

comp <- data.frame(
  c("Tasa de incumplimiento", "Beta de score", "OR de score (+10 puntos)",
    "AUC", "R2 de McFadden"),
  c(paste0(round(mean(datos1$default) * 100, 1), " %"),
    round(coef(modelo1)["score"], 4), round(exp(10 * coef(modelo1)["score"]), 4),

```

```

    round(as.numeric(auc(roc1)), 4), round(pseudo_r2_mcfadden(modelo1), 4)),
c(paste0(round(mean(default_b) * 100, 1), " %"),
  round(coef(modelo1b)["score"], 4), round(exp(10 * coef(modelo1b)["score"]), 4),
  round(as.numeric(auc(roc1b)), 4), round(pseudo_r2_mcfadden(modelo1b), 4)),
row.names = NULL)
names(comp) <- c("Indicador", "Especificación de la guía",
  "Especificación corregida")
kable(comp, booktabs = TRUE, linesep = "",
  caption = "Modelo 1. Efecto de corregir el signo de \\emph{score}: la estimación no cambia de calidad")
# La guía pide cargar la base "Traindata" del aula virtual (Excel) y modelar
# 'cumple' contra todas las demás variables.
#
# El bloque busca el archivo en ./datos/. Si NO está disponible, construye una
# base sustituta simulada con la misma estructura, para que el documento sea
# íntegramente reproducible. Basta copiar el archivo real en
# ./datos/Traindata.xlsx y volver a compilar: nada más cambia en el análisis.
ruta_xlsx <- file.path("datos", "Traindata.xlsx")
ruta_csv <- file.path("datos", "Traindata.csv")

if (file.exists(ruta_xlsx)) {
  traindata <- as.data.frame(read_excel(ruta_xlsx))
  origen <- "archivo Traindata.xlsx del aula virtual"
} else if (file.exists(ruta_csv)) {
  traindata <- read.csv(ruta_csv)
  origen <- "archivo Traindata.csv del aula virtual"
} else {
  # ---- Base sustituta simulada: estructura típica de una tabla de scoring ----
  set.seed(2025)
  m <- 1200
  traindata <- data.frame(
    edad = round(rnorm(m, 38, 11)),
    ingresos = round(rlnorm(m, log(2800), 0.45)), # sesgo a la derecha
    score = round(rnorm(m, 620, 70)),
    genero = rbinom(m, 1, 0.48), # 0 = F, 1 = M
    monto_prestamo = round(rnorm(m, 6200, 2100)),
    plazo_meses = sample(c(12, 24, 36, 48, 60), m, replace = TRUE),
    antiguedad_laboral = round(abs(rnorm(m, 5, 4)), 1), # años
    creditos_previos = rpois(m, 1.6),
    tasa_endeudamiento = round(pmin(pmax(rnorm(m, 0.35, 0.12), 0.02), 0.95), 3)
  )
  # Predictor lineal del CUMPLIMIENTO: los signos se invierten respecto al
  # Modelo 1, porque aquí el evento y = 1 es cumplir, no incumplir.
  eta <- -5.10 + 0.018 * traindata$edad + 0.00022 * traindata$ingresos +
    0.0075 * traindata$score - 0.00009 * traindata$monto_prestamo -
    0.011 * traindata$plazo_meses + 0.075 * traindata$antiguedad_laboral -
    0.16 * traindata$creditos_previos - 2.40 * traindata$tasa_endeudamiento -
    0.22 * traindata$genero
  traindata$cumple <- rbinom(m, 1, 1 / (1 + exp(-eta)))
  origen <- paste("base SUSTITUTA simulada: el archivo Traindata del aula",
    "virtual no estaba disponible al compilar este documento")
}
traindata$cumple <- as.numeric(traindata$cumple) # asegura respuesta 0/1
# La notación 'cumple ~ .' significa: cumple explicada por TODAS las demás
# variables del data.frame, que es exactamente lo que solicita la guía.
modelo2 <- glm(cumple ~ ., family = binomial(link = "logit"), data = traindata)

```

```

summary(modelo2)
p2 <- fitted(modelo2)
roc2 <- roc(traindata$cumple, p2, quiet = TRUE)
b2 <- coef(modelo2)
sig2 <- summary(modelo2)$coefficients[, 4] < 0.05
mc2 <- matriz_confusion(traindata$cumple, p2, 0.5)
corte_opt <- as.numeric(coords(roc2, "best", best.method = "youden",
                             ret = "threshold")[1])
mc2_opt <- matriz_confusion(traindata$cumple, p2, corte_opt)
kable(tabla_coeficientes(modelo2), booktabs = TRUE, linesep = "", digits = 5,
      caption = "Modelo 2 (Traindata). Coeficientes, significancia, odds ratios e intervalos al 95 %%." L
# Odds ratios reescalados a incrementos con significado práctico.
esc <- c(edad = 5, ingresos = 500, score = 25, genero = 1, monto_prestamo = 1000,
        plazo_meses = 12, antiguedad_laboral = 1, creditos_previos = 1,
        tasa_endeudamiento = 0.10)
esc <- esc[names(esc) %in% names(b2)]
ef2 <- data.frame(
  names(esc), unname(esc),
  round(exp(b2[names(esc)] * esc), 4),
  round(100 * (exp(b2[names(esc)] * esc) - 1), 2),
  ifelse(b2[names(esc)] > 0, "Menor riesgo", "Mayor riesgo"),
  ifelse(sig2[names(esc)], "Sí", "No"),
  row.names = NULL)
names(ef2) <- c("Variable", "Incremento", "OR reescalado",
               "Cambio en odds de cumplir (%)", "Lectura de riesgo",
               "Signif. 5%")
kable(ef2, booktabs = TRUE, linesep = "",
      caption = "Modelo 2. Odds ratios reescalados a incrementos financieramente interpretables, con su l
diag2 <- tabla_diagnostics(modelo2, traindata$cumple)
# Se añade la regla EPV (eventos por variable): min(n1, n0)/k >= 10 es el
# tamaño mínimo recomendado para que los errores estándar sean confiables.
epv <- min(table(traindata$cumple)) / (ncol(traindata) - 1)
# setNames() se usa en lugar de nombres acentuados entre comillas invertidas,
# para que el código sea válido también en locales sin soporte UTF-8 (Windows).
fila_epv <- setNames(
  data.frame("Eventos por variable (EPV)", sprintf("%.1f", epv),
            ">= 10: muestra suficiente", stringsAsFactors = FALSE),
  names(diag2))
diag2 <- rbind(diag2, fila_epv)
kable(diag2, booktabs = TRUE, linesep = "",
      caption = "Modelo 2. Diagnósticos del ajuste y desempeño predictivo.")
# Se seleccionan como continuas las numéricas con más de 10 valores distintos.
cont2 <- setdiff(names(traindata)[sapply(traindata, function(v)
  is.numeric(v) && length(unique(v)) > 10)], "cumple")
ggplot(logit_empirico(traindata, "cumple", cont2),
  aes(x = x_medio, y = logit_emp)) +
  geom_point(size = 1) +
  geom_smooth(method = "lm", se = FALSE, linewidth = 0.4) +
  facet_wrap(~ variable, scales = "free_x") +
  labs(x = "Valor medio del decil", y = "logit empírico")
grafico_roc(roc2)
ggplot(data.frame(p = p2, y = factor(traindata$cumple,
  labels = c("No cumple (0)", "Cumple (1)"))),
  aes(x = p, fill = y)) +
  geom_density(alpha = 0.45, linewidth = 0.3) +

```

```
scale_fill_grey(start = 0.25, end = 0.75) +  
labs(x = "Probabilidad predicha de cumplimiento", y = "Densidad",  
     fill = "Observado") +  
theme(legend.position = "bottom", legend.key.size = unit(0.3, "cm"))
```

B Anexo B: entorno de cómputo

R version 4.3.3 (2024-02-29)

Paquetes: ggplot2 3.4.4 | pROC 1.18.5 | car 3.1.2 | readxl 1.4.3 | knitr 1.45

Semillas: 123 (Modelo 1), 2025 (base sustituta Traindata)

Fuente de datos del Modelo 2: base SUSTITUTA simulada: el archivo Traindata del aula virtual no estaba di